

# Ficha técnica — Classificação de batimentos cardíacos com Deep Learning

M10 — Deep Learning · Trabalho Final · Problema 6 | Código: [github.com/ljb6/ecg-ml](https://github.com/ljb6/ecg-ml)

Grupo: Victor Franceschini, Gustavo Rost, Lucca Becker, Lyon Alves e Caio Murilo

## PROBLEMA

Uma clínica de cardiologia usa monitores Holter: são mais de 100 mil batimentos por exame de 24 h, e hoje um técnico revisa o traçado inteiro. O sistema **marca os batimentos suspeitos** para o técnico revisar só esses. É uma **triagem, não um diagnóstico**: a decisão é sempre do profissional.

**Erro crítico:** o falso negativo (arritmia não marcada, que o técnico não vai olhar). O falso positivo custa só tempo de revisão.

## DADOS

- Fonte:** ECG Heartbeat Categorization (Kaggle; Kachuee et al., 2018), derivado do MIT-BIH Arrhythmia Database (PhysioNet): 47 pacientes, gravações de 1975–1979.
- Formato:** cada exemplo é um batimento já recortado: 187 amostras a 125 Hz (~1,5 s), normalizadas entre 0 e 1 e completadas com zeros.
- Tamanho:** 87.554 batimentos de treino e 21.892 de teste, já separados.
- Classes (AAMI), no treino:** N normal 82,8% · Q desconhecido 7,3% · V ventricular 6,6% · S supraventricular 2,5% · F fusão 0,7%.
- Divisão:** 15% do treino separado para validação, estratificado (74.420 / 13.134). Todas as escolhas usam a validação; o teste é usado uma única vez.

## ARQUITETURA ESCOLHIDA: CNN 1D

- 4 blocos **Conv1D** (32, 64, 128 e 128 filtros; kernel 5 = 40 ms) + BatchNorm + ReLU + MaxPool(2) → GlobalAveragePooling → Dropout 0,3 → Dense 64 → Softmax (5 classes).
- 143.621 parâmetros; campo receptivo de 608 ms no último bloco.
- Treino:** Adam (0,001), entropia cruzada ponderada pela **raiz quadrada do peso balanceado** de cada classe, early stopping e redução da taxa de aprendizado monitorando a macro-F1 de validação. 31 épocas, ~12 min em CPU.
- Por que CNN:** filtros locais compartilhados reconhecem a forma do batimento (QRS, ondas P e T) em qualquer posição. Superou a MLP (linha de base) e as variantes com RNN (GRU).

## MÉTRICA PRINCIPAL E RESULTADO

**Macro-F1:** média simples do F1 das 5 classes. A acurácia engana, porque responder "normal" para tudo já acerta 82,8%.

| Modelo (conjunto de teste)   | Acurácia     | Macro-F1     | Revoc. S    | Revoc. F    |
|------------------------------|--------------|--------------|-------------|-------------|
| "Sempre Normal" (referência) | 0,828        | 0,181        | 0,00        | 0,00        |
| MLP (linha de base)          | 0,969        | 0,854        | 0,71        | 0,80        |
| <b>CNN 1D</b>                | <b>0,984</b> | <b>0,914</b> | <b>0,80</b> | <b>0,86</b> |

Comparação com RNN, pela macro-F1 na validação: GRU 0,792 · GRU com leitura invertida 0,814 · CNN + GRU 0,870 · CNN 1D 0,917.

**Triagem (normal × suspeito):** o batimento é marcado quando 1 – P(normal) passa de um limiar escolhido na validação para encontrar 99% dos anormais.


**25,5%**  
dos batimentos  
passam a ser  
revisados pelo  
técnico

**98,6%**  
dos batimentos  
anormais são  
marcados (teste)

**0,99**  
revocação da classe  
N; o erro mais  
comum é S → N  
(19%)

## PRINCIPAIS LIMITAÇÕES

- Divisão por batimento, não por paciente:** os mesmos pacientes estão no treino e no teste. Um classificador que só memoriza (1-NN) chega a macro-F1 de 0,889, e cada batimento de teste tem um "irmão" no treino ~9 vezes mais próximo que um batimento típico da classe. **Os resultados são otimistas para pacientes novos.**
- Representatividade:** 47 pacientes, um único hospital, equipamento dos anos 1970 e uma derivação. Desempenho em outros aparelhos e populações é desconhecido.
- Classe S:** 19% são confundidos com normais; o recorte isolado perde a informação de prematuridade.
- Entrada já recortada:** num Holter real é preciso detectar os picos R e segmentar os batimentos antes; essa etapa não foi avaliada.
- Probabilidades não calibradas** (efeito dos pesos de classe): o limiar precisa ser revalidado com dados da clínica.
- Uso clínico** exige piloto com exames da clínica, validação por paciente, regularização na ANVISA (software como dispositivo médico) e tratamento dos exames como dados sensíveis pela LGPD.



Matrizes de confusão no teste, normalizadas por linha (linha = classe real, coluna = prevista). A CNN reduz a confusão de S com N de 26% para 19% e a de F com N de 14% para 7%.